

Александр Чеченев

AI Engineer (LLM, RAG, оценка качества, агенты)

Санкт-Петербург или удалённо, английский B2

alexchea319@gmail.com t.me/alexchea318 linkedin.com/in/alexander-chechenev vk.me/schechenev

Кратко

4+ года в разработке, с 2023 года создаю LLM-продукты. Веду разработку во всех 7 сервисах enterprise RAG-платформы: делаю сквозные фичи от техплана до релиза. 3 внедрения on-prem с точностью ответов 89–96% по оценке LLM-as-a-Judge.

Опыт

Just AI (Jay Knowledge Hub)

апрель 2024 – настоящее время

Enterprise RAG-платформа в реестре отечественного ПО, внедрена в банках и на производстве.

AI Engineer (RAG) декабрь 2025 – настоящее время

- Построил оценку качества и регрессионный гейт в CI: тест-сеты, модель-судья. Охват ассистента вырос с 55 до 3 000 вопросов при прежней точности 89%. Python, pytest, CI
- Провёл версионирование документов через все 7 сервисов: версия стала атрибутом чанка, без переиндексации и ломки API. Kotlin, Python, TypeScript
- Отвечаю за on-prem поставку под 10 000 пользователей и 1 RPS на пользователя: LTS-ветки, порядок выката общих пакетов. Docker, Kubernetes, Jenkins
- Устранил 3 источника лишних расходов: повторную генерацию (семантический кэш), повторную оплату краулера, списания при сбое биллинга. 2 инцидента P1 решены в тот же день. Memcached, Grafana, Sentry
- Отвечаю за поиск: гибридный поиск, трансформация запроса, реранкинг, GraphRAG. Перенёс проверку прав в сам поиск и закрыл 5 обходов в 4 сервисах. Elasticsearch, Neo4j, RBAC
- Разложил цикл разработки на регламенты для людей и AI-агентов: 2 инженера делают объём, на который нужно было 3. Опубликовал MCP-сервер базы знаний (5 инструментов). Claude Code, MCP, GitLab CI

Senior Frontend Developer апрель 2024 – декабрь 2025

- Владел frontend-архитектурой: 4 репозитория, 12 разработчиков, 0 уязвимостей в аудитах. Разработал диалоговый интерфейс с потоковым ответом и цитатами. React, Next.js, TypeScript
- Руководил миграцией монорепозитория из 12 проектов (React 16 → 19, webpack → Vite, Jest → Vitest), загрузка 3 проектов ускорилась в 2,7 раза. Vite, Vitest, Node.js

НеоБИТ, Development Team Lead и PM

сентябрь 2023 – апрель 2024

Генеративный AI для соцсетей и мессенджеров, сервисы на Go в Kubernetes.

- Руководил командой 5 инженеров (Go, frontend, DevOps, ML): 3 продукта на генеративном AI от требований до production за 17 спринтов, все в срок.
- Совмещал роли тимлида и PM: 15 Epic из бизнес-требований, 8 демо руководству заказчика, 3 поставки в закрытый контур по госконтрактам.

Ранние роли

НеоБИТ, Frontend и Fullstack Developer. 2022–2023: React, библиотека компонентов, первые сервисы на Go.
LG Electronics Russia R&D Lab, Data Science Intern. Лето 2021: методы оптимизации градиентного спуска.

Стек

LLM и RAG: агенты, tool calling, MCP, гибридный поиск, реранкинг, GraphRAG, Elasticsearch, Neo4j, LlamaIndex

Оценка качества: LLM-as-a-Judge, тест-сеты, регрессия промптов, метрики в CI, стоимость и задержка

Разработка: Python, FastAPI, Kotlin, Go, TypeScript, React, Next.js, PostgreSQL, MinIO, Memcached

Поставка: Docker, Kubernetes, Jenkins, GitLab CI, on-prem, Prometheus, Grafana, Sentry

Образование и выступления

Специалитет «Информационно-аналитические системы безопасности», СПбПУ

2025: доклад «Свой ChatGPT в 2021 по цене парсера анекдотов», фестиваль «Елагин Pro»